

Limpieza y preparación de datos para el análisis

Dr. Juan Carlos Baena Silva

Introducción

En este documento se presenta un proceso completo de **limpieza y preparación de datos** aplicado a un conjunto de datos real de películas de IMDb. El objetivo es transformar un dataset crudo, con valores faltantes, formatos inconsistentes y nombres de columnas no estandarizados, en un dataset limpio, estructurado y listo para análisis estadístico o visualización.

Carga de Librerías

librerías

```
if (!require(stringr)) install.packages("stringr")  
if (!require(RKaggle)) install.packages("RKaggle")
```

```
library(RKaggle)  
library(tidyverse)  
library(lubridate)  
library(stringr)
```

Carga del Dataset

Dataset de IMDb

```
# Cargar el dataset
```

```
movie_data <- get_dataset("ashpalsingh1525/imdb-movies-data")
```

```
# Ver estructura inicial
```

```
head(movie_data)
```

```
# A tibble: 6 x 12
```

	names	date_x	score	genre	overview	crew	orig_title	stat
	<chr>	<chr>	<dbl>	<chr>	<chr>	<chr>	<chr>	<chr>

1	Creed ~	03/02~	73	Dram~	After d~	Mich~	Creed III	Rele
---	---------	--------	----	-------	----------	-------	-----------	------

2	Avatar~	12/15~	78	Scie~	Set mor~	Sam ~	Avatar: T~	Rele
---	---------	--------	----	-------	----------	-------	------------	------

3	The Su~	04/05~	76	Anim~	While w~	Chri~	The Super~	Rele
---	---------	--------	----	-------	----------	-------	------------	------

4	Mummies	01/05~	70	Anim~	Through~	Ósca~	Momias	Rele
---	---------	--------	----	-------	----------	-------	--------	------

5	Superc~	03/17~	61	Acti~	Good-			
---	---------	--------	----	-------	-------	--	--	--

he~	Skee~	Supercell	Relea~	English		7.70e7		
-----	-------	-----------	--------	---------	--	--------	--	--

6	Cocain~	02/23~	66	Thri~	Inspire~	Keri~	Cocaine B~	Rele
---	---------	--------	----	-------	----------	-------	------------	------

```
# i 2 more variables: revenue <dbl>, country <chr>
```

Vista Rápida del Dataset

```
glimpse(movie_data)
```

```
Rows: 10,178
```

```
Columns: 12
```

```
$ names      <chr> "Creed III", "Avatar: The Way of Water",  
$ date_x     <chr> "03/02/2023", "12/15/2022", "04/05/2023",  
$ score      <dbl> 73, 78, 76, 70, 61, 66, 80, 83, 59, 58,  
$ genre      <chr> "Drama, Action", "Science Fiction, Adver  
$ overview   <chr> "After dominating the boxing world, Adon  
$ crew       <chr> "Michael B. Jordan, Adonis Creed, Tessa  
$ orig_title  <chr> "Creed III", "Avatar: The Way of Water",  
$ status     <chr> "Released", "Released", "Released", "Re  
$ orig_lang   <chr> "English", "English", "English", "Spanis  
$ budget_x    <dbl> 750000000, 4600000000, 1000000000, 12300000  
$ revenue     <dbl> 271616668, 2316794914, 724459031, 342000  
$ country     <chr> "AU", "AU", "AU", "AU", "US", "AU", "AU"
```

Descripción del Dataset Original

- names - Nombre de las películas
- date_x - Fecha de estreno
- score - Puntuación en IMDb (0-100)
- genre - Género de la película
- overview - Descripción breve
- crew - Director y actores principales
- orig_title - Título original
- status - Estado (Released, Post Production, etc.)
- orig_lang - Lenguaje original
- budget_x - Presupuesto (USD)
- revenue - Recaudación (USD)
- country - País de producción

Exploración Inicial

Dimensiones del Dataset

```
# Dimensiones del dataset
cat("Observaciones:", nrow(movie_data), "\n")
Observaciones: 10178
cat("Variables:", ncol(movie_data), "\n")
Variables: 12
```


Exploración Inicial

Valores nulos

```
# Valores nulos por columna
```

```
sapply(movie_data, function(x) sum(is.na(x)))
```

names	date_x	score	genre	overview
0	0	0	85	0
status	orig_lang	budget_x	revenue	country
0	0	0	0	0

Resultado

El dataset tiene **10,178 observaciones** y **12 variables**. La columna con valores faltantes es `genre`.

Limpieza de Columnas y Renombrado

Selección y renombrado de columnas relevantes

```
# Seleccionar solo las columnas relevantes para el análisis
```

```
movie_clean <- movie_data |>
```

```
  select(  
    title = names,  
    original = orig_title,  
    date = date_x,  
    genre,  
    score,  
    lang = orig_lang,  
    country,  
    budget = budget_x,  
    revenue  
  )
```

Limpieza de Columnas y Renombrado

Renombrado de columnas a formato estándar

```
# Renombrar columnas a formato estándar (minúsculas, sin es
```

```
movie_clean <- movie_clean |>  
  rename_with(~ str_to_lower(.) |>  
              str_replace_all("\\s+", "_"))
```

```
# Ver estructura final
```

```
head(movie_clean)
```

```
# A tibble: 6 x 9
```

	title	original	date	genre	score	lang	
	<chr>	<chr>	<chr>	<chr>	<dbl>	<chr>	<chr>
1	Creed III	Creed I~	03/0~	Dram~	73	Engl~	A
2	Avatar: The Way of Wa~	Avatar:~	12/1~	Scie~	78	Engl~	A
3	The Super Mario Bros.~	The Sup~	04/0~	Anim~	76	Engl~	A
4	Mummies	Momias	01/0~	Anim~	70	Span~	A
5	Supercell	Superce~	03/1~	Acti~	61	Engl~	U
6	Cocaine Bear	Cocaine~	02/2~	Thri~	66	Engl~	A

Transformación de Variables Numéricas: Presupuesto y Recaudación

Limpiar y convertir budget y revenue

```
# Función para limpiar valores monetarios (eliminar $, , y  
clean_money <- function(x) {  
  x <- str_remove_all(x, "[\\$,,]")          # Elimina $ y  
  x <- str_replace_all(x, "\\.", "")         # Elimina punt  
  as.numeric(x)  
}
```

Transformación de Variables Numéricas: Presupuesto y Recaudación

Limpiar y convertir budget y revenue

```
# Aplicar a budget y box_office
```

```
movie_clean <- movie_clean |>  
  mutate(  
    budget = clean_money(budget),  
    revenue = clean_money(revenue)  
  )
```

```
# Convertir a millones para facilitar lectura
```

```
movie_clean <- movie_clean |>  
  mutate(  
    budget_mil = budget / 1e6,  
    revenue_mil = revenue / 1e6  
  )
```

```
movie_clean |>
```

Transformación de Variables Numéricas: Presupuesto y Recaudación

Eliminar columnas originales

```
# Eliminar columnas originales
```

```
movie_clean <- movie_clean |>  
  select(-budget, -revenue)
```

```
# Ver resultados
```

```
movie_clean |>  
  select(title, budget_mil, revenue_mil) |>  
  head(5)
```

```
# A tibble: 5 x 3
```

	title	budget_mil	revenue_mil
	<chr>	<dbl>	<dbl>
1	Creed III	750	272.
2	Avatar: The Way of Water	4600	2317.
3	The Super Mario Bros. Movie	100	724

Calcular Rentabilidad (ROI)

```
# ROI = Recaudación / Presupuesto
movie_clean <- movie_clean |>
  mutate(roi = revenue_mil / budget_mil) |>
  filter(!is.na(budget_mil), budget_mil > 0) # Solo películas

# Top 5 películas con mayor ROI
movie_clean |>
  select(title, original, budget_mil, revenue_mil, roi) |>
  arrange(desc(roi)) |>
  head(5)
```

Table 1: Top 5 Películas con Mayor Rentabilidad (ROI)

title	original	budget_1
Down	Down	0
Onsen porno chitai		0
Girl in the Box	Girl in the Box	0
Tom and Jerry: The Movie	Tom and Jerry: The Movie	0
The Umbrellas of Cherbourg	Les Parapluies de Cherbourg	0

Note:

ROI = Recaudación / Presupuesto (en millones USD)

* *

Estandarización de Géneros

Separar géneros múltiples y convertir a minúsculas

```
# Convertir a minúsculas y separar géneros en filas individuales
```

```
movie_genre <- movie_clean %>%  
  mutate(genre = str_to_lower(genre)) %>%  
  separate_rows(genre, sep = ",") %>%  
  mutate(genre = str_trim(genre))
```


```
# Ver conteo de géneros
```

```
movie_genre %>%  
  count(genre) %>%  
  arrange(desc(n))
```

Table 2: Frecuencia de Géneros en el Dataset IMDb


genre	n
drama	3812
comedy	2943
action	2752
thriller	2605
adventure	1890
romance	1576
horror	1554
animation	1468
family	1407
fantasy	1382
crime	1272
science fiction	1261
mystery	862
history	422
war	282
music	277
documentary	217

Visualización: Distribución de Géneros



Observación: “Drama”, “Comedy” y “Action” son los géneros más populares. “western” y “tv movie” son menos representados.

Visualización: Relación entre Calificación y Rentabilidad



Coeficiente de correlación entre IMDb Rating y ROI: 0.004

Interpretación: Hay una **correlación débil positiva** (~0.15–0.25).

Esto sugiere que **una buena calificación no garantiza rentabilidad económica**, y viceversa.

¡Muchas películas de bajo presupuesto con ROI alto son poco calificadas por críticos!

Convertir date a formato de año

Aplicamos la función `mdy()` de `lubridate` para convertir strings a fechas

```
movie_clean <- movie_clean %>%  
  mutate(date = mdy(date),  
         year = year(date))
```

Frecuencia de Años

```
# Conteo de películas por año
movie_clean |>
  count(year) |>
  filter(!is.na(year)) |>
  arrange(desc(n)) |>
  head(10)
```

Table 3: Top 10 Años con Más Películas

year	n
2022	954
2021	627
2019	470
2018	469
2020	449
2017	434
2023	403
2016	389
2015	350
2014	343

Años con mayor presupuesto

```
movie_clean |>
  group_by(year) |>
  summarise(annual_budget = sum(budget_mil)) |>
  arrange(desc(annual_budget)) |>
  head(10)
```

Table 4: Años con Mayor Presupuesto Total (millones USD)

year	annual_budget
2022	1709150.3
2021	1076321.9
2023	1071565.4
2019	837651.8
2020	747484.9
2018	723600.4
2017	712957.9
2016	546119.6
2012	517702.7
2015	482959.9

Años con mayor ROI

```
movie_clean |>
  group_by(year) |>
  summarise(total_roi = sum(roi)) |>
  arrange(desc(total_roi)) |>
  head(10) |>
  mutate(total_roi =total_roi / 1e1)
```


Table 5: Años con Mayor ROI Total (dividido por 10 para escala)

year	total_roi
2019	257722333.4
1972	23580368.4
2016	7716412.3
1993	5285397.3
1964	5013795.3
2006	680965.0
2022	667147.1
1941	360955.4
2020	360545.0
2023	94425.6

Análisis por Año: Evolución del Presupuesto y ROI


```
# Promedios por año
trend_data <- movie_clean |>
  group_by(year) |>
  summarise(
    avg_budget = mean(budget_mil, na.rm = TRUE),
    avg_roi = mean(roi, na.rm = TRUE),
    n = n()
  ) |>
  filter(n > 5) # Solo años con al menos 5 películas
```

Evolución del ROI por Año (escala x10)



El ROI se multiplica por 10 para que sea visible junto al presupuesto

Evolución del Presupuesto y ROI por Año



Línea roja: ROI * 10 para comparación visual

Insight:

- *El presupuesto promedio ha aumentado desde 1975.*
- *El ROI ha disminuido ligeramente: las películas cuestan más, pero no generan proporcionalmente más ingresos.*

Guardar el Dataset Limpio

Usamos la función `write_csv()` de `readr` para guardar el dataset limpio en CSV

```
# Guardar el dataset final en CSV
```

```
write_csv(movie_clean, "movie_DB_clean.csv")
```

```
# Verificar que se guardó correctamente
```

```
movie_check <- read_csv("movie_DB_clean.csv")
```

```
cat("Dataset limpio guardado con", nrow(movie_check), "filas")
```

```
Dataset limpio guardado con 10178 filas y 11 columnas.
```

Conclusión

Hemos transformado un dataset crudo de IMDb en un **dataset limpio, estructurado y listo para análisis**. Los pasos realizados incluyen:

Etapa	Técnica en R
Carga de datos	<code>get_dataset()</code>
Selección de columnas	<code>select()</code>
Renombrado	<code>rename_with()</code>
Limpieza monetaria	<code>str_remove_all(), as.numeric()</code>
Creación de nuevas variables	<code>mutate(roi = revenue_mil / budget_mil)</code>
Visualización	<code>ggplot2</code>
Guardado	<code>write_csv()</code>

- IMDb Dataset - Kaggle
- Wickham, H., & Grolemund, G. (2017). *R for Data Science*. O'Reilly Media.
- RStudio Cheat Sheets:
<https://rstudio.com/resources/cheatsheets/>